LAPORAN STUDI KASUS

DESAIN KONSEPTUAL SISTEM KOMPUTASI BERBASIS COMPUTER VISION UNTUK KLASIFIKASI BENTUK SEL DAN STATUS GRAM BAKTERI DARI CITRA MIKROSKOPIS DIGITAL

(Studi Kasus A: Pengolahan Citra Digital untuk Klasifikasi Sel)

Disusun oleh:

Alfiz Ilham (260411101100105)

PROGRAM STUDI TEKNIK KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS SYIAH KUALA

2026

ABSTRAK

Identifikasi bakteri secara konvensional melalui pewarnaan Gram dan pengamatan morfologi sel bergantung pada keterampilan teknisi laboratorium dan rentan terhadap variasi antar-pengamat. Studi kasus ini merancang sistem Computer Vision berbasis Convolutional Neural Network (CNN) dengan pendekatan multi-task learning untuk mengklasifikasikan bentuk sel (cocci, bacilli) dan status Gram (positif, negatif) bakteri secara simultan dari citra mikroskopis digital. Desain menggunakan backbone ResNet-50 dengan transfer learning, dua classification head independen, dan pra-pemrosesan berupa segmentasi watershed untuk memisahkan sel yang saling bertumpuk. Dataset DIBaS dipakai sebagai acuan melalui lookup table yang memetakan label spesies ke label bentuk sel dan status Gram berdasarkan taksonomi mikrobiologi standar. Karena DIBaS memberi label pada level spesies, bukan langsung bentuk sel atau status Gram, studi ini menekankan bahwa klaim performa bersifat hipotesis yang memerlukan pengujian empiris dengan protokol evaluasi leave-species-out, guna memastikan model mempelajari pola morfologi dan pewarnaan yang sebenarnya, bukan sekadar menghafal identitas spesies. Desain ini diharapkan menjadi kerangka awal alat bantu diagnostik mikrobiologi yang mempercepat identifikasi bakteri tanpa menggantikan konfirmasi baku emas melalui kultur dan uji biokimia.

Kata kunci: klasifikasi bakteri, Computer Vision, Convolutional Neural Network, pewarnaan Gram, multi-task learning.

DAFTAR ISI

ABSTRAK i
DAFTAR TABEL ii
DAFTAR GAMBAR iii
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 2
1.3 Tujuan 2
1.4 Manfaat 2
BAB II TINJAUAN PUSTAKA 3
2.1 Morfologi Sel Bakteri 3
2.2 Mekanisme Pewarnaan Gram 3
2.3 Computer Vision dan Convolutional Neural Network 4
BAB III GAMBARAN KASUS DAN METODE 5
3.1 Gambaran Umum Pipeline 5
3.2 Akuisisi dan Pra-pemrosesan Citra 5
3.3 Ekstraksi Fitur dan Arsitektur Klasifikasi 6
3.4 Dataset Acuan 7
BAB IV HASIL DAN PEMBAHASAN 9
4.1 Alur Kerja Sistem pada Tahap Inferensi 9
4.2 Keterkaitan Fitur Biologis dengan Representasi Komputasi 9
4.3 Hipotesis dan Protokol Evaluasi 10
4.4 Keunggulan dan Keterbatasan Desain 10
BAB V PENUTUP 12
5.1 Kesimpulan 12
5.2 Saran 12
DAFTAR PUSTAKA 13
LAMPIRAN 15

DAFTAR TABEL

Tabel 1. Karakteristik dataset DIBaS sebagai acuan desain sistem 7

DAFTAR GAMBAR

Gambar 1. Diagram pipeline sistem klasifikasi bakteri berbasis Computer Vision 5
Gambar 2. Contoh struktur lookup table pemetaan label spesies ke bentuk sel dan status Gram 6

BAB I

PENDAHULUAN

1.1 Latar Belakang

Ahli mikrobiologi mengidentifikasi bakteri melalui pewarnaan Gram dan pengamatan morfologi sel di bawah mikroskop cahaya, sebuah teknik yang dipakai sejak ditemukan oleh Hans Christian Gram pada tahun 1884 (Beveridge, 2001; Popescu & Doyle, 1996). Hasil pewarnaan ini bergantung pada keterampilan teknisi laboratorium yang membacanya, sehingga dua pengamat bisa sampai pada kesimpulan berbeda dari sampel yang sama (Samuel et al., 2016). Samuel dkk. (2016) mengevaluasi 6.115 spesimen klinis di empat laboratorium rujukan tersier dan mencatat tingkat kesalahan Gram stain antara 0,4% hingga 2,7%; dari kesalahan tersebut, 24% berasal dari kekeliruan pembaca, dengan rentang 9% hingga 45% tergantung laboratorium.

Convolutional Neural Network (CNN) kini mampu mengklasifikasikan citra biomedis dengan akurasi tinggi, termasuk citra bakteri dari mikroskop digital (Zhang et al., 2023). Talo (2019) melatih ResNet-50 pada dataset DIBaS dan mencapai akurasi 99,2% untuk 33 kategori bakteri. Penelitian ini mengusulkan sistem yang menggabungkan prinsip morfologi dan pewarnaan Gram dengan arsitektur CNN tersebut, untuk mengklasifikasikan bentuk sel dan status Gram bakteri sekaligus dari satu citra.

1.2 Rumusan Masalah

Rumusan masalah pada studi kasus ini mencakup tiga pertanyaan berikut:

- Bagaimana merancang pipeline Computer Vision yang mengklasifikasikan bentuk sel (cocci, bacilli) dan status Gram (positif/negatif) bakteri secara simultan dari satu citra mikroskopis?
- Bagaimana mengatasi noise dan sel yang saling bertumpuk pada citra mikroskop digital sebelum citra diproses oleh model klasifikasi?

- Parameter biologis apa yang relevan diubah menjadi fitur komputasi agar model dapat membedakan bentuk sel dan status Gram secara akurat?

1.3 Tujuan

Studi kasus ini bertujuan merancang arsitektur sistem Computer Vision berbasis CNN dengan pendekatan multi-head classification, yang memprediksi bentuk sel dan status Gram bakteri secara bersamaan dari satu backbone jaringan saraf tiruan.

1.4 Manfaat

Desain ini memberi tiga manfaat utama. Mahasiswa mendapat kerangka berpikir untuk mengintegrasikan ilmu biologi mikroba dengan teknik Computer Vision. Ahli mikrobiologi memperoleh gambaran alat bantu diagnostik awal yang dapat mempercepat identifikasi bakteri. Peneliti berikutnya memperoleh acuan arsitektur multi-head yang dapat dikembangkan lebih lanjut pada dataset bakteri lain.

BAB II

TINJAUAN PUSTAKA

2.1 Morfologi Sel Bakteri

Bakteri memiliki tiga bentuk sel dasar yang menjadi ciri morfologis dalam identifikasi mikrobiologi klasik: cocci (bulat), bacilli (batang), dan spiral (heliks atau melengkung). Cabeen dan Jacobs-Wagner (2005) menjelaskan bahwa bentuk sel terbentuk dari protein sitoskeletal, proses sintesis dinding sel, dan tekanan evolusioner yang memengaruhi kebugaran organisme pada lingkungan tertentu. Bentuk sel tetap stabil secara genetik pada sebagian besar spesies, sehingga dapat dijadikan fitur visual yang andal untuk klasifikasi berbasis citra.

2.2 Mekanisme Pewarnaan Gram

Pewarnaan Gram membagi bakteri menjadi dua kelompok berdasarkan struktur dan ketebalan lapisan peptidoglikan pada dinding sel. Bakteri Gram-positif memiliki lapisan peptidoglikan tebal yang mempertahankan kompleks kristal violet-iodin selama dekolorisasi dengan alkohol, sehingga tampak ungu di bawah mikroskop. Bakteri Gram-negatif memiliki lapisan peptidoglikan tipis dan membran luar berbasis lipopolisakarida; kompleks pewarna utama luruh saat dekolorisasi, dan sel menyerap warna kontras safranin yang tampak merah muda hingga merah (Beveridge, 2001; Popescu & Doyle, 1996; Paray et al., 2023). Prosedur ini terdiri atas empat tahap: pewarnaan primer dengan kristal violet, pemberian iodin sebagai mordan, dekolorisasi dengan aseton-etanol, dan pewarnaan kontras dengan safranin (Jones & Dever, 1984). Perbedaan warna dan intensitas pada tahap akhir ini menjadi fitur visual yang dapat diekstraksi oleh algoritma Computer Vision.

2.3 Computer Vision dan Convolutional Neural Network

CNN mengekstraksi fitur dari citra melalui lapisan konvolusi berlapis, dari fitur tingkat rendah seperti tepi dan tekstur hingga fitur tingkat tinggi seperti bentuk objek dan pola warna (Zhang et al., 2023). Transfer learning memungkinkan

jaringan yang telah dilatih pada dataset besar seperti ImageNet digunakan kembali untuk tugas baru dengan data terbatas, melalui penyesuaian (fine-tuning) pada lapisan akhir jaringan. Talo (2019) menerapkan transfer learning dengan ResNet-50 pada dataset DIBaS dan mencapai akurasi 99,2% untuk 33 kategori bakteri, mengungguli AlexNet dan VGGNet pada dataset yang sama. Mai dan Ishibashi (2021) membandingkan beberapa arsitektur pada dataset DIBaS: VGG16 mencapai 98,25%, sementara model depthwise separable CNN yang mereka usulkan mencapai 96,28% dengan parameter jauh lebih sedikit. Wu dan Gadsden (2023) melaporkan EfficientNet-Lite mencapai 97,38% pada dataset serupa dengan efisiensi komputasi tinggi.

Yachnaya dkk. (2024) mengusulkan Multi-headed ResNet untuk meningkatkan generalisasi terhadap galur bakteri baru: beberapa output head dipasang pada kedalaman blok ResNet yang berbeda, seluruhnya memprediksi label yang sama (spesies), agar jaringan memanfaatkan fitur multi-resolusi dari citra koloni. Studi ini melaporkan bahwa split data acak menghasilkan akurasi di atas 90%, tetapi split berdasarkan galur (leave-strain-out) menjatuhkan akurasi menjadi 41,6% pada level spesies dan 64,06% pada level genus, menunjukkan risiko model menghafal galur spesifik alih-alih mempelajari pola morfologi umum. Desain studi kasus ini berbeda: dua head independen memprediksi dua atribut berbeda (bentuk sel dan status Gram) dari satu backbone bersama, sebuah pendekatan multi-task learning standar. Prinsip Yachnaya dkk. yang relevan bukan arsitekturnya, melainkan peringatannya tentang generalisasi antar-galur, yang menjadi dasar protokol evaluasi leave-species-out pada Bagian 4.3.

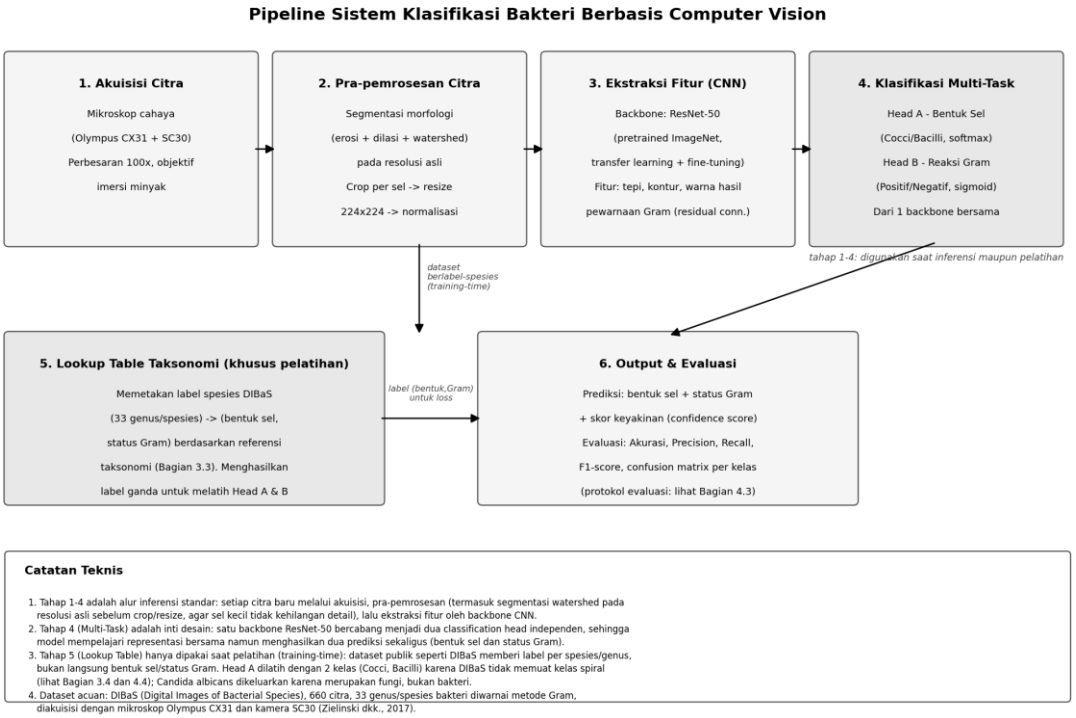
Pada citra mikroskop, sel bakteri sering tumpang tindih dalam satu bidang pandang. Beucher dan Meyer (2018) mengembangkan transformasi watershed untuk memisahkan objek yang saling bertumpuk berdasarkan garis pemisah topografis. Abeyrathna dkk. (2022) menerapkan operasi morfologis dikombinasikan dengan watershed khusus untuk citra sel bakteri, dan menunjukkan metode ini mengurangi kesalahan segmentasi akibat sel yang menempel satu sama lain.

BAB III

GAMBARAN KASUS DAN METODE

3.1 Gambaran Umum Pipeline

Sistem yang dirancang terdiri atas enam tahap yang membentuk satu alur kerja, dari akuisisi citra hingga evaluasi hasil klasifikasi. Gambar 1 menyajikan diagram blok lengkap dari arsitektur ini.



Gambar 1. Diagram pipeline sistem klasifikasi bakteri berbasis Computer Vision

3.2 Akuisisi dan Pra-pemrosesan Citra

Citra masukan berasal dari mikroskop cahaya dengan objektif imersi minyak pada perbesaran 100x, mengikuti protokol akuisisi dataset DIBaS menggunakan mikroskop Olympus CX31 dan kamera SC30 (Zieliński et al., 2017; Mai & Ishibashi, 2021). Resolusi asli citra adalah 2048 × 1532 piksel.

Pra-pemrosesan mengatasi noise dan variasi kualitas citra sebelum citra diteruskan ke tahap ekstraksi fitur, melalui tiga langkah berikut, dijalankan pada tahap inferensi maupun pelatihan kecuali disebutkan lain.

- Segmentasi morfologis pada resolusi asli (2048×1532 piksel) menggunakan operasi erosi dan dilasi dikombinasikan dengan transformasi watershed, untuk memisahkan sel bakteri yang saling bertumpuk sehingga setiap sel tersegmentasi dapat dianalisis sebagai objek individual (Beucher & Meyer, 2018; Abeyrathna et al., 2022). Segmentasi dilakukan sebelum pengubahan ukuran agar sel berukuran kecil tidak kehilangan detail akibat downsampling dini.
- Setiap hasil segmentasi sel di-crop dan diubah ukurannya ke dimensi 224×224 piksel, sesuai dimensi masukan ResNet-50.
- Normalisasi intensitas piksel, untuk mengurangi variasi akibat pencahayaan mikroskop yang tidak konsisten.

Khusus pada tahap pelatihan, augmentasi data (rotasi, flipping, zoom, pergeseran) diterapkan untuk memperbesar variasi data mengingat ukuran dataset DIBaS yang terbatas; augmentasi tidak dipakai saat inferensi.

3.3 Ekstraksi Fitur dan Arsitektur Klasifikasi

Backbone sistem adalah ResNet-50 yang telah dilatih pada ImageNet, kemudian disesuaikan untuk klasifikasi bakteri melalui transfer learning. Pendekatan ini dipilih karena Talo (2019) melaporkan arsitektur ini mencapai akurasi 99,2% untuk klasifikasi 33 spesies bakteri dalam dataset DIBaS, mengungguli AlexNet dan VGGNet pada dataset yang sama; model depthwise separable CNN yang diusulkan Mai dan Ishibashi (2021) mencapai 96,28% pada tugas serupa dengan parameter jauh lebih sedikit. VGG16 dipertimbangkan sebagai pembanding, dengan akurasi 98,25% yang dilaporkan oleh Nasip dan Zengin (2018) dan dirangkum dalam tinjauan Mai dan Ishibashi (2021); EfficientNet-Lite mencapai 97,38% dengan efisiensi komputasi tinggi (Wu & Gadsden, 2023). Perlu dicatat bahwa seluruh angka ini adalah akurasi klasifikasi 33 spesies bakteri, bukan akurasi klasifikasi bentuk sel atau status Gram; lihat Bagian 4.3 untuk pembahasan selisih keduanya. Koneksi residual pada ResNet-50 memungkinkan jaringan dalam dilatih tanpa vanishing gradient, sehingga berpotensi mengekstraksi fitur dari tepi dan tekstur hingga pola warna hasil pewarnaan Gram dan kontur bentuk sel.

Representasi fitur dari backbone diteruskan ke dua classification head independen melalui pendekatan multi-task learning, dengan parameter backbone dibagikan (shared) antara kedua tugas:

- **Head A, klasifikasi bentuk sel:** lapisan fully-connected dengan fungsi aktivasi softmax dan dua kelas keluaran (cocci, bacilli). Dataset DIBaS tidak memuat kelas bakteri berbentuk spiral (lihat Bagian 3.4 dan 4.4), sehingga Head A dibatasi pada dua bentuk yang tersedia datanya; perluasan ke kelas spiral memerlukan dataset tambahan di luar DIBaS.
- **Head B, klasifikasi status Gram:** lapisan fully-connected dengan fungsi aktivasi sigmoid untuk klasifikasi biner (Gram-positif, Gram-negatif).

Desain ini melatih satu backbone untuk dua tugas sekaligus, sehingga mengurangi kebutuhan komputasi dibanding melatih dua model terpisah. Pembelajaran kedua tugas saling menguatkan representasi fitur, karena bentuk sel dan status Gram berkaitan dengan struktur dinding sel yang sama.

Dataset publik seperti DIBaS memberi label berdasarkan nama spesies atau genus, bukan langsung berupa label bentuk sel atau status Gram. Sistem menggunakan lookup table yang memetakan setiap label spesies ke pasangan label target, berdasarkan referensi taksonomi mikrobiologi (Cabeen & Jacobs-Wagner, 2005; Beveridge, 2001). Tabel ini dipakai pada tahap pelatihan untuk menghasilkan label ganda dari label spesies tunggal, sehingga satu dataset melatih dua classification head sekaligus. Gambar 2 menunjukkan contoh struktur pemetaan ini menggunakan kelas yang benar-benar terdapat dalam DIBaS. Candida albicans, satu-satunya kelas DIBaS yang merupakan fungi dan bukan bakteri, dikeluarkan dari pelatihan kedua head; beberapa kelas dengan bentuk sel ambigu (misalnya Acinetobacter yang kokobasil atau Actinomyces yang berfilamen) ditandai tersendiri dan dibahas sebagai keterbatasan pada Bagian 4.4.

Contoh Struktur Lookup Table: Label Spesies DIBaS -> (Bentuk Sel, Status Gram)

Label Spesies (DIBaS)	Bentuk Sel	Status Gram
Staphylococcus aureus	Cocci	Positif
Lactobacillus plantarum	Bacilli	Positif
Escherichia coli	Bacilli	Negatif
Pseudomonas aeruginosa	Bacilli	Negatif
Neisseria gonorrhoeae	Cocci (diplokokus)	Negatif
Candida albicans	Dikeluarkan dari training*	N/A

... (total 33 kelas genus/spesies dalam dataset DIBaS dipetakan dengan pola yang sama; lihat Tabel 1)

Fungsi lookup table dalam pipeline:

Pada tahap pelatihan, label spesies asli dataset DIBaS dipetakan ke sepasang label target (bentuk sel, status Gram) menggunakan tabel ini, disusun berdasarkan referensi taksonomi mikrobiologi standar (Cabeen & Jacobs-Wagner, 2005; Beveridge, 2001). Candida albicans (*) adalah fungi, bukan bakteri, sehingga dikeluarkan dari pelatihan Head A dan Head B; lihat Bagian 3.4 dan 4.4.

Gambar 2. Contoh struktur lookup table pemetaan label spesies ke bentuk sel dan status Gram

3.4 Dataset Acuan

Desain ini menggunakan dataset DIBaS (Digital Images of Bacterial Species) sebagai acuan, karena banyak dipakai sebagai tolok ukur pada penelitian klasifikasi citra bakteri berbasis CNN. Dataset ini dikumpulkan oleh Chair of Microbiology, Jagiellonian University, Krakow, Polandia, berisi 660 citra mikroskopis dari 33 kelas genus/spesies yang diwarnai dengan metode Gram (Zieliński et al., 2017); satu dari 33 kelas tersebut, Candida albicans, adalah fungi dan bukan bakteri, sehingga dikeluarkan dari pelatihan Head A dan Head B pada studi kasus ini (lihat Bagian 3.3). Talo (2019) mencatat jumlah citra sedikit berbeda, yaitu 689 (20-23 citra per kelas); perbedaan ini kemungkinan berasal dari revisi dataset setelah publikasi awal. Tabel 1 merangkum karakteristik dataset ini.

Tabel 1. Karakteristik dataset DIBaS sebagai acuan desain sistem

Atribut	**Keterangan**
Jumlah citra	660 citra asli
Jumlah kelas	33 genus/spesies bakteri
Resolusi	2048 × 1532 piksel
Alat akuisisi	Mikroskop Olympus CX31 dengan kamera SC30, perbesaran 100x (imersi minyak)
Metode pewarnaan	Pewarnaan Gram standar

Sumber	Chair of Microbiology, Jagiellonian University, Krakow, Polandia (Zieliński et al., 2017)

BAB IV

HASIL DAN PEMBAHASAN

4.1 Alur Kerja Sistem pada Tahap Inferensi

Pada tahap inferensi, citra baru yang belum pernah dilihat model melewati tahap 1 hingga 4 pada pipeline (Gambar 1) secara berurutan. Citra diakuisisi dari mikroskop, melewati segmentasi watershed pada resolusi asli bila sel saling bertumpuk lalu di-crop dan dinormalisasi, diteruskan ke backbone ResNet-50 untuk ekstraksi fitur, kemudian representasi fitur tersebut diteruskan ke Head A dan Head B secara paralel. Kedua head menghasilkan prediksi probabilitas untuk bentuk sel dan status Gram secara independen. Lookup table pada tahap 5 hanya dipakai pada tahap pelatihan untuk menghasilkan label ganda dari dataset berlabel-spesies; pada inferensi, keluaran model langsung berupa prediksi bentuk sel dan status Gram tanpa melalui lookup table.

4.2 Keterkaitan Fitur Biologis dengan Representasi Komputasi

Parameter biologis yang relevan untuk klasifikasi diterjemahkan menjadi fitur komputasi melalui konvolusi berlapis, dengan tiga keterkaitan utama.

- **Bentuk sel.** Lapisan konvolusi awal pada ResNet-50 mendeteksi tepi dan kontur objek, yang digabungkan pada lapisan lebih dalam menjadi representasi bentuk geometris keseluruhan sel. Proses ini serupa dengan cara ahli mikrobiologi mengenali bentuk cocci, bacilli, atau spiral secara visual (Cabeen & Jacobs-Wagner, 2005).
- **Warna hasil pewarnaan Gram.** Lapisan konvolusi diharapkan menangkap pola distribusi warna piksel, ungu untuk Gram-positif dan merah muda untuk Gram-negatif, sebagai representasi numerik dari perbedaan ketebalan peptidoglikan dinding sel (Beveridge, 2001). Keterkaitan ini adalah asumsi desain berdasarkan label taksonomi pada lookup table, bukan hasil pengujian langsung terhadap piksel citra; label status Gram yang diturunkan dari nama spesies berisiko membuat model menghafal identitas spesies alih-alih benar-benar mempelajari warna, dan

warna hasil pewarnaan juga dapat bervariasi tergantung kamera dan medium (Yachnaya et al., 2024). Pengujian leave-species-out pada Bagian 4.3 dirancang untuk memeriksa apakah keterkaitan ini benar-benar dipelajari.

- **Susunan sel.** Pola susunan sel tunggal, berpasangan, berantai, atau bergerombol adalah informasi tambahan yang relevan untuk identifikasi presumtif genus bakteri (Cabeen & Jacobs-Wagner, 2005). Pola ini tidak diprediksi oleh Head A maupun Head B pada desain saat ini; penambahan head ketiga (Head C) untuk klasifikasi susunan sel adalah arah pengembangan yang disebutkan pada Bagian 5.2.

4.3 Hipotesis dan Protokol Evaluasi

Evaluasi performa memakai metrik akurasi, presisi, recall, dan F1-score, dihitung dari confusion matrix pada kedua classification head secara terpisah, mengikuti standar evaluasi pada literatur klasifikasi citra bakteri (Mai & Ishibashi, 2021; Ahmad et al., 2023). Dataset DIBaS tidak menyertakan informasi galur (strain) per citra (Yachnaya et al., 2024), sehingga split per-galur yang ideal untuk mengukur generalisasi tidak dapat diterapkan langsung pada DIBaS; sebagai pendekatan terdekat yang tersedia, evaluasi memakai skema leave-species-out, yaitu validasi silang di mana spesies tertentu dikeluarkan penuh dari data latih pada tiap lipatan, untuk menguji apakah Head B (status Gram) benar-benar belajar dari warna dan bukan menghafal identitas spesies (lihat Bagian 4.2). Skema ini dipilih sebagai satu-satunya protokol evaluasi yang dipakai, menggantikan pembagian acak 70:20:10 yang berisiko membocorkan kemiripan antar-citra spesies yang sama ke data uji. Perlu diperhatikan bahwa distribusi kelas DIBaS tidak merata: 11 dari 33 kelas adalah genus Lactobacillus yang berbentuk bacilli, sehingga label bentuk sel condong ke bacilli dan evaluasi perlu memperhitungkan ketidakseimbangan ini, misalnya melalui metrik F1-score per kelas.

Studi kasus ini adalah desain konseptual; sistem belum diimplementasikan dan diuji secara empiris, sehingga tidak ada angka akurasi aktual yang dapat dilaporkan untuk tugas klasifikasi bentuk sel dan status Gram. Angka 99,2% (Talo,

2019) dan 99,91% (Ahmad et al., 2023) yang sering dikutip sebagai tolok ukur performa tinggi pada dataset serupa merupakan akurasi klasifikasi 33 spesies bakteri, bukan akurasi bentuk sel atau status Gram, dan tidak dapat diekstrapolasi langsung ke tugas dua-atribut pada studi kasus ini. Hipotesis yang diajukan adalah: performa Head A dan Head B pada evaluasi acak standar akan lebih tinggi daripada performa pada evaluasi leave-species-out, mencerminkan pola yang dilaporkan Yachnaya dkk. (2024) pada klasifikasi spesies (di atas 90% pada split acak, turun menjadi 41,6% pada split per-galur). Selisih besar antara kedua skema evaluasi akan menjadi indikasi bahwa label status Gram belum teruji secara independen dari identitas spesies (lihat Bagian 4.2). Kesalahan klasifikasi kemungkinan lebih sering terjadi pada kelas dengan bentuk sel ambigu, seperti Acinetobacter (kokobasil) dan Actinomyces (berfilamen), karena keduanya sulit dipetakan secara tegas ke kategori cocci atau bacilli (lihat Bagian 3.4).

4.4 Keunggulan dan Keterbatasan Desain

Desain ini memberi tiga keunggulan dibanding sistem klasifikasi tunggal. Satu backbone CNN menangani dua tugas klasifikasi, mengurangi kebutuhan pelatihan dan penyimpanan dua model terpisah. Pembelajaran kedua tugas saling menguatkan representasi fitur, karena bentuk sel dan status Gram berkaitan secara biologis dalam struktur dinding sel. Transfer learning mengurangi kebutuhan data pelatihan dalam jumlah besar, relevan mengingat keterbatasan ukuran dataset mikrobiologi publik seperti DIBaS.

Empat keterbatasan perlu diperhatikan pada implementasi nyata. Model berisiko sulit mengenali galur bakteri baru yang tidak termasuk data pelatihan, sebagaimana diperingatkan pada penelitian Yachnaya dkk. (2024), sehingga evaluasi leave-species-out pada Bagian 4.3 menjadi langkah wajib, bukan pilihan, sebelum klaim generalisasi dapat dibuat. Dataset DIBaS tidak memuat kelas bakteri berbentuk spiral dan menyertakan satu kelas fungi (Candida albicans) yang dikeluarkan dari pelatihan, sehingga Head A pada desain ini terbatas pada dua kelas (cocci, bacilli) dan tidak dapat digeneralisasi ke bentuk spiral tanpa data tambahan (lihat Bagian 3.3 dan 3.4); beberapa kelas lain (Acinetobacter, Actinomyces,

Bifidobacterium) memiliki bentuk ambigu yang sulit dipetakan secara tegas. Performa model bergantung pada kualitas citra mikroskop dan konsistensi protokol pewarnaan Gram, karena variasi teknis preparasi sampel memengaruhi hasil (CarbGeM Inc., 2025). Sistem ini berfungsi sebagai alat bantu diagnostik awal, bukan pengganti konfirmasi melalui kultur dan uji biokimia yang tetap menjadi baku emas identifikasi bakteri.

BAB V

PENUTUP

5.1 Kesimpulan

Studi kasus ini merancang sistem Computer Vision yang mengklasifikasikan bentuk sel dan status Gram bakteri secara simultan dari citra mikroskopis digital. Sistem memakai transfer learning dengan backbone ResNet-50 yang dimodifikasi menjadi arsitektur multi-head, didukung pra-pemrosesan berupa segmentasi morfologis dan transformasi watershed untuk mengatasi sel bertumpuk. Lookup table pemetaan taksonomi memungkinkan dataset berlabel-spesies seperti DIBaS melatih dua tugas klasifikasi tanpa anotasi tambahan secara manual.

Literatur klasifikasi 33 spesies pada dataset DIBaS menunjukkan ResNet-50 dengan transfer learning mencapai akurasi tinggi (Talo, 2019), yang mendukung kelayakan teknis pemilihan backbone ini sebagai titik awal. Namun klasifikasi bentuk sel dan status Gram adalah tugas berbeda dari klasifikasi spesies, dan desain ini belum diuji secara empiris, sehingga pernyataan performa untuk kedua tugas tersebut masih berstatus hipotesis yang perlu dibuktikan melalui implementasi dan evaluasi leave-species-out (lihat Bagian 4.3). Generalisasi model pada galur bakteri baru dan robustitas terhadap variasi kualitas citra di laboratorium berbeda memerlukan pengujian lebih lanjut sebelum sistem ini dipakai pada praktik klinis.

5.2 Saran

Pengembangan lanjutan disarankan menguji arsitektur ini pada dataset bakteri di luar DIBaS, termasuk galur yang diisolasi dari laboratorium berbeda, untuk mengukur generalisasi model secara langsung. Perbandingan kuantitatif antara ResNet-50, VGG16, dan EfficientNet pada kondisi data dan parameter yang sama juga disarankan, untuk memastikan pemilihan backbone didasarkan pada pengujian empiris, bukan hanya tinjauan literatur.

DAFTAR PUSTAKA

Abeyrathna, D. L. B., Nguyen, S. H., & Pham, T. D. (2022). A morphological post-processing approach for overlapped segmentation of bacterial cell images. *Machine Learning and Knowledge Extraction, 4*(4), 924-942.

Ahmad, F., Khan, M. U. G., Tahir, A., & Masud, F. (2023). Deep ensemble approach for pathogen classification in large-scale images using patch-based training and hyper-parameter optimization. *BMC Bioinformatics, 24*(1), 273. https://doi.org/10.1186/s12859-023-05398-7

Aytac, O., Senol, F. F., Kivrak, T., Toraman, Z. A., Gun, M. V., Goktas, O. F., Dogan, S., & Tuncer, T. (2025). MACNeXt-based bacteria species detection. *Microorganisms, 13*(12), 2689. https://doi.org/10.3390/microorganisms13122689

Beucher, S., & Meyer, F. (2018). The morphological approach to segmentation: The watershed transformation. In *Mathematical morphology in image processing* (hlm. 433-481). CRC Press.

Beveridge, T. J. (2001). Use of the Gram stain in microbiology. *Biotechnic & Histochemistry, 76*(3), 111-118.

Cabeen, M. T., & Jacobs-Wagner, C. (2005). Bacterial cell shape. *Nature Reviews Microbiology, 3*(8), 601-610.

CarbGeM Inc. (2025, 11 Maret). *AI-powered Gram stain image analysis for microbial classification and diagnostics* [White paper]. https://carbgem.com/en/news-20250311-en/

Jones, G. L., & Dever, S. M. (1984). *The Gram stain: A new look at an old tool*. Centers for Disease Control.

Mai, D.-T., & Ishibashi, K. (2021). Small-scale depthwise separable convolutional neural networks for bacteria classification. *Electronics, 10*(23), 3005. https://doi.org/10.3390/electronics10233005

Nasip, O. F., & Zengin, K. (2018). Deep learning-based classification of bacteria on the DIBaS dataset [dikutip dalam Mai & Ishibashi, 2021, Tabel 5; detail publikasi primer belum terverifikasi penulis].

Paray, A. A., dkk. (2023). Gram staining: A brief review. *International Journal of Research and Review.*

Popescu, A., & Doyle, R. J. (1996). The Gram stain after more than a century. *Biotechnic & Histochemistry, 71*(3), 145-151.

Samuel, L. P., Balada-Llasat, J.-M., Harrington, A., & Cavagnolo, R. (2016). Multicenter assessment of Gram stain error rates. *Journal of Clinical Microbiology, 54*(6), 1442-1447. https://doi.org/10.1128/JCM.03066-15

Talo, M. (2019). An automated deep learning approach for bacterial image classification. *arXiv*, arXiv:1912.08765. https://doi.org/10.48550/arXiv.1912.08765

Wu, Y., & Gadsden, S. A. (2023). Machine learning algorithms in microbial classification: A comparative analysis. *Frontiers in Artificial Intelligence, 6*, 1200994. https://doi.org/10.3389/frai.2023.1200994

Yachnaya, V. O., dkk. (2024). Improving generalization in classification of novel bacterial strains: A multi-headed ResNet approach for microscopic image

classification. *Computer Optics, 48*(5), 772-781. https://doi.org/10.18287/2412-6179-CO-1464

Zhang, J., Li, C., Yin, Y., Zhang, J., & Grzegorzek, M. (2023). Applications of artificial neural networks in microorganism image analysis: A comprehensive review from conventional multilayer perceptron to popular convolutional neural network and potential visual transformer. *Artificial Intelligence Review, 56*(2), 1013-1070. https://doi.org/10.1007/s10462-022-10192-7

Zieliński, B., Plichta, A., Misztal, K., Spurek, P., Brzychczy-Włoch, M., & Ochońska, D. (2017). Deep learning approach to bacterial colony classification. *PLoS ONE, 12*(9), e0184554. https://doi.org/10.1371/journal.pone.0184554

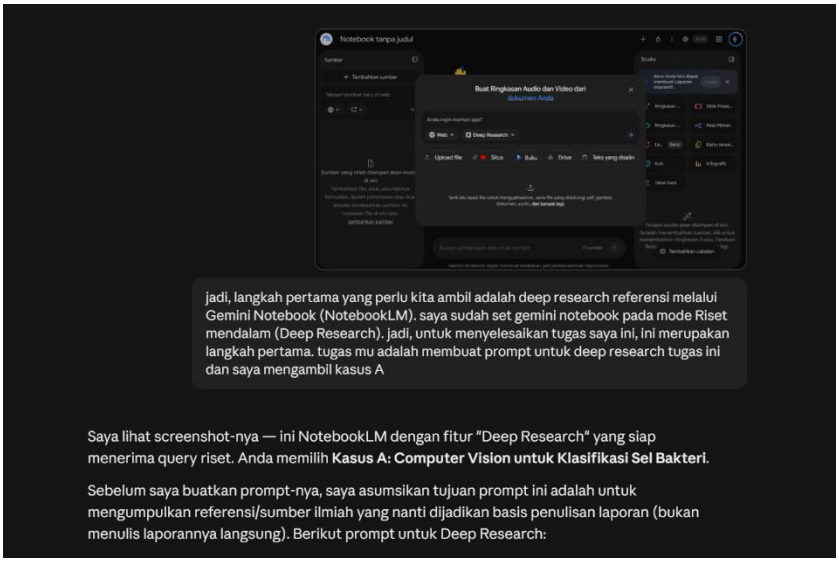
Lampiran

Lampiran 1. Dokumentasi Proses Penggunaan AI

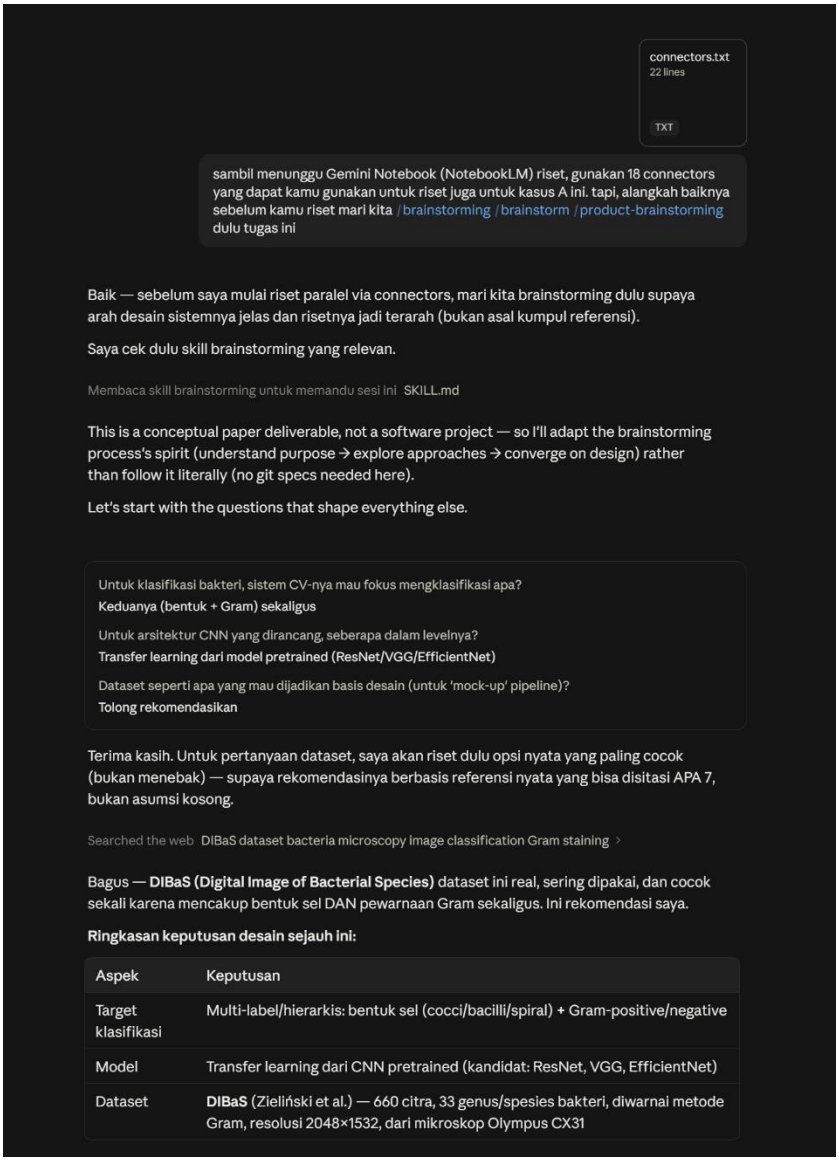
Lampiran ini memuat dokumentasi tahapan penggunaan Claude.ai dan NotebookLM dalam proses riset referensi Studi Kasus A. Setiap gambar disertai keterangan yang menjelaskan langkah yang ditampilkan.



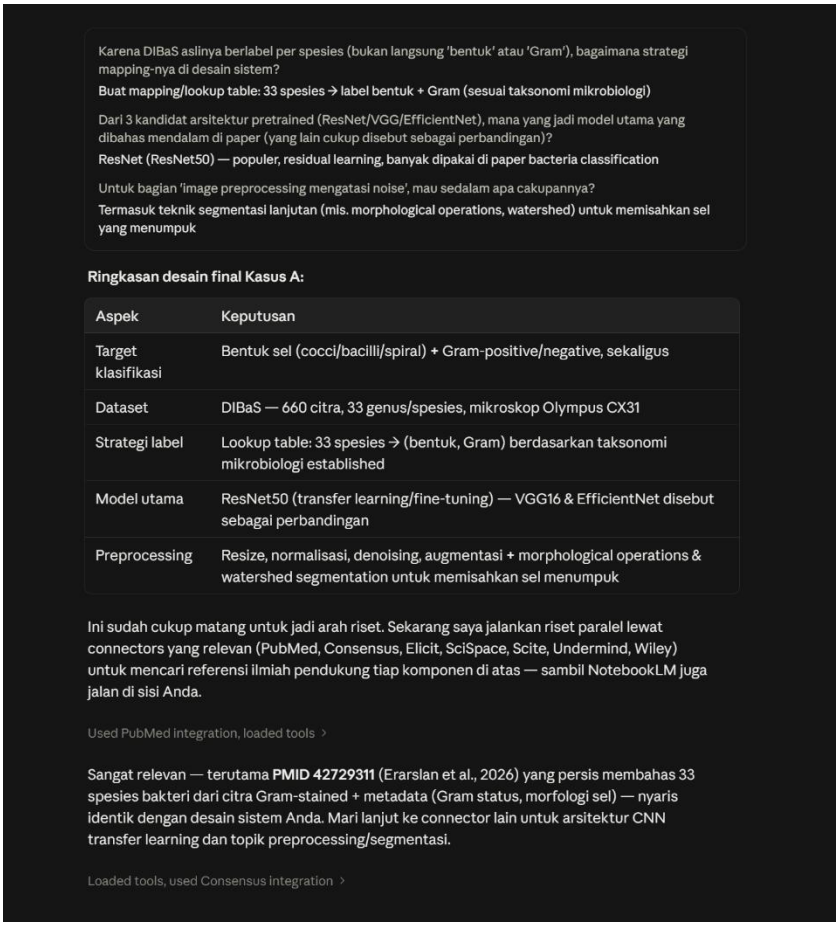
Gambar 1. *Permintaan kepada Claude.ai untuk memastikan pemahaman terhadap tugas.*



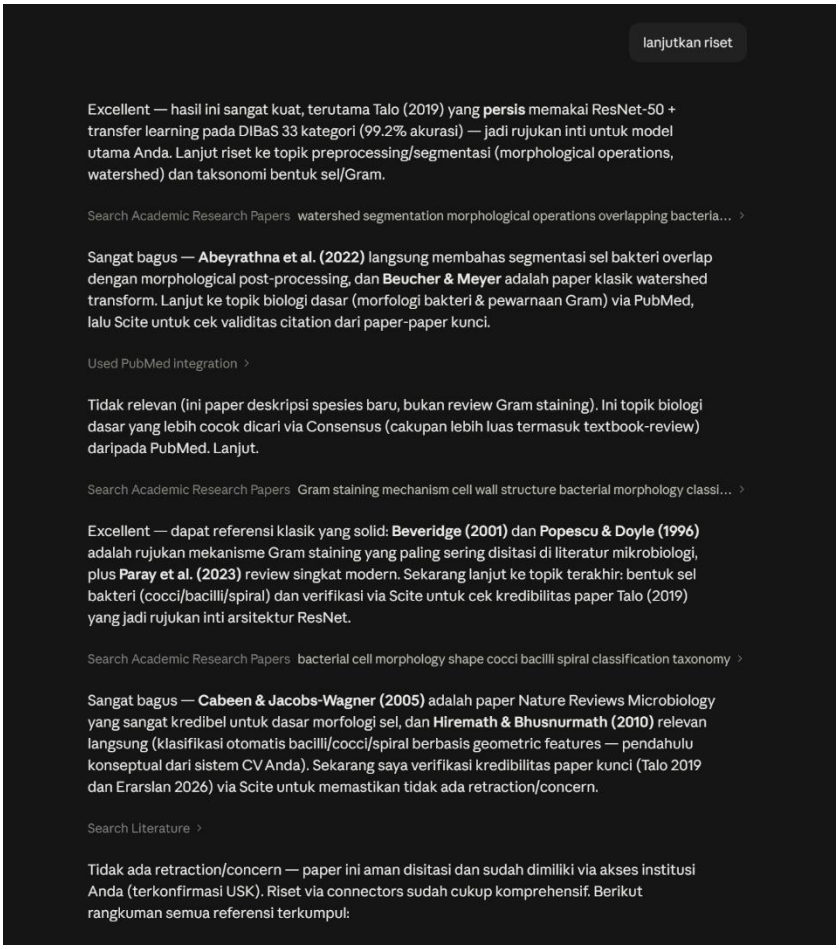
Gambar 2. *Pemilihan Kasus A untuk ditinjau dan permintaan pembuatan detail prompt bagi NotebookLM untuk riset referensi.*



Gambar 3. *Permintaan riset brainstorming awal menggunakan skill /brainstorming dan connector riset yang relevan, sehingga riset tidak hanya bergantung pada NotebookLM (daftar lengkap pada Lampiran 2).*



Gambar 4. *Konfirmasi konteks dan tugas oleh Claude.ai untuk memastikan rencana riset sesuai.*



Gambar 5. *Persetujuan kepada Claude.ai untuk melanjutkan riset sesuai rencana yang telah disetujui.*



Ringkasan Referensi Kasus A (Sejauh Ini)

1. Biologi Dasar — Morfologi & Pewarnaan Gram

- Cabeen, M.T. & Jacobs-Wagner, C. (2005). Bacterial cell shape. *Nature Reviews Microbiology*.
- Beveridge, T.J. (2001). Use of the Gram stain in microbiology. *Biotechnic & Histochemistry*.
- Popescu, A. & Doyle, R.J. (1996). The Gram stain after more than a century. *Biotechnic & Histochemistry*.
- Paray, A.A. et al. (2023). Gram Staining: A Brief Review. *International Journal of Research and Review*.

2. CV/CNN untuk Klasifikasi Bakteri (Model Inti)

- Talo, M. (2019). An Automated Deep Learning Approach for Bacterial Image Classification (ResNet-50 + transfer learning, DIBaS 33 kelas, akurasi 99.2%). *arXiv*.
- Erarslan, A., Ciftci, F., & Rahebi, J. (2026). Automated microbial recognition from gram-stained micrographs via CNN and metadata decision support — akurasi 0.84, integrasi metadata Gram status + morfologi. *Frontiers in Cellular and Infection Microbiology*. DOI
- Wu, Y. & Gadsden, S.A. (2023). Machine learning algorithms in microbial classification: a comparative analysis (perbandingan AlexNet/VGGNet/ResNet/DenseNet pada dataset 660 citra, 33 spesies). *Frontiers in AI*.
- Wonohadidjojo, D.M. (2022). Classification of Bacterial Images using Transfer Learning, Optimized Training and ResNet-50. *Eduvest*.

3. Preprocessing & Segmentasi

- Beucher, S. & Meyer, F. (2018 reprint). The Morphological Approach to Segmentation: The Watershed Transformation. *Mathematical Morphology in Image Processing*.
- Abeyrathna, D.L.B. et al. (2022). A Morphological Post-Processing Approach for Overlapped Segmentation of Bacterial Cell Images. *Machine Learning and Knowledge Extraction*.

4. Precedent Konseptual (Fitur Geometris → Bentuk Sel)

- Hiremath, P.S. & Bhusnurmath, R.A. (2010). Automatic classification of bacterial cells in digital microscopic images.
- Liu, J. et al. (2001). CMEIAS: A Computer-Aided System for the Image Analysis of Bacterial Morphotypes. *Microbial Ecology*.

5. Dataset

- Zieliński, B. et al. — DIBaS (Digital Image of Bacterial Species) dataset.

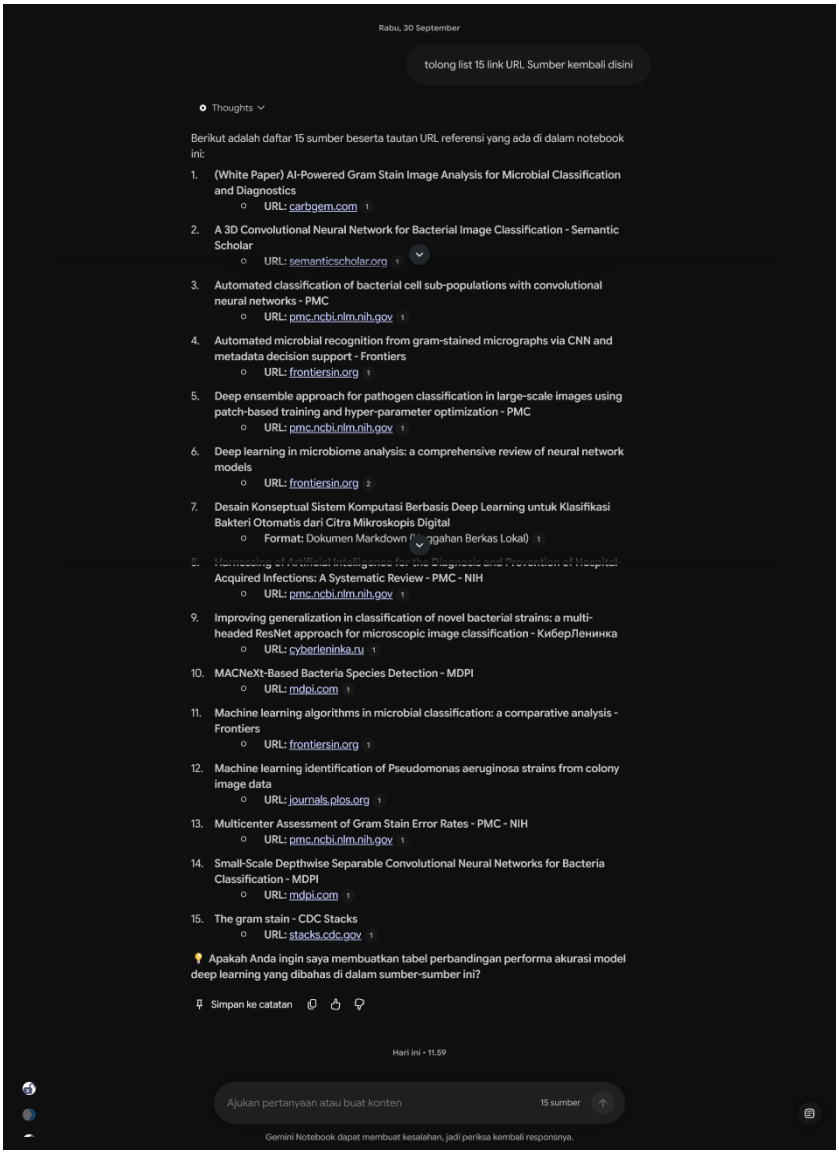
Referensi ini sudah sangat kuat untuk menopang seluruh bagian laporan (Tinjauan Biologi, Desain Arsitektur, Preprocessing). Sambil menunggu hasil dari NotebookLM Anda, apakah Anda ingin saya:

1. **Mulai menyusun draft laporan** (Judul, Abstrak, Pendahuluan & Tinjauan Biologi) berdasarkan referensi ini, atau
2. **Buat diagram arsitektur pipeline sistem** dulu (visual CV/CNN Kasus A) sebagai kerangka sebelum menulis teks?

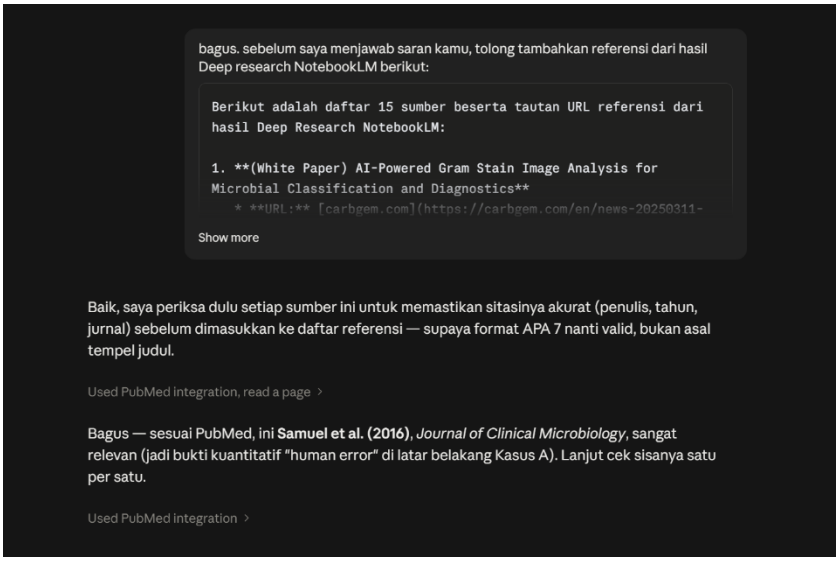
Gambar 6. *Hasil riset yang disajikan Claude.ai secara terstruktur.*



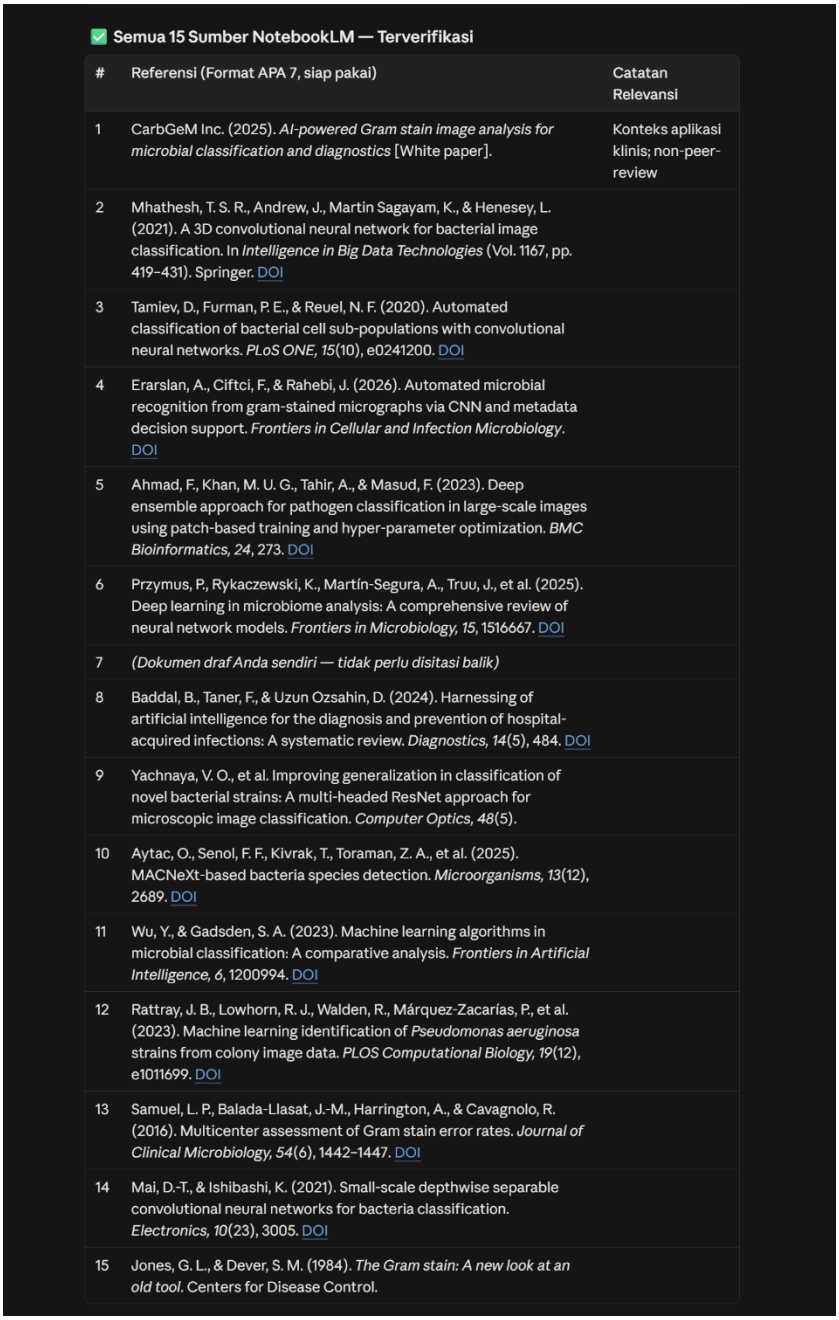
Gambar 7. *NotebookLM telah menyelesaikan riset dan menyajikan daftar referensi.*



Gambar 8. *Permintaan daftar URL sumber lengkap kepada NotebookLM.*



Gambar 9. *Penyampaian URL sumber dari NotebookLM kepada Claude.ai dan permintaan penggabungan referensi.*



Semua 15 Sumber NotebookLM — Terverifikasi

#	Referensi (Format APA 7, siap pakai)	Catatan Relevansi
1	CarbGeM Inc. (2025). *AI-powered Gram stain image analysis for microbial classification and diagnostics* [White paper].	Konteks aplikasi klinis; non-peer-review
2	Mhathesh, T. S. R., Andrew, J., Martin Sagayam, K., & Henesey, L. (2021). A 3D convolutional neural network for bacterial image classification. In *Intelligence in Big Data Technologies* (Vol. 1167, pp. 419–431). Springer. DOI	
3	Tamiev, D., Furman, P. E., & Reuel, N. F. (2020). Automated classification of bacterial cell sub-populations with convolutional neural networks. *PLoS ONE, 15*(10), e0241200. DOI	
4	Erarslan, A., Ciftci, F., & Rahebi, J. (2026). Automated microbial recognition from gram-stained micrographs via CNN and metadata decision support. *Frontiers in Cellular and Infection Microbiology*. DOI	
5	Ahmad, F., Khan, M. U. G., Tahir, A., & Masud, F. (2023). Deep ensemble approach for pathogen classification in large-scale images using patch-based training and hyper-parameter optimization. *BMC Bioinformatics, 24*, 273. DOI	
6	Przymus, P., Rykaczewski, K., Martín-Segura, A., Truu, J., et al. (2025). Deep learning in microbiome analysis: A comprehensive review of neural network models. *Frontiers in Microbiology, 15*, 1516667. DOI	
7	*(Dokumen draf Anda sendiri — tidak perlu disitasi balik)*	
8	Baddal, B., Taner, F., & Uzun Ozsahin, D. (2024). Harnessing of artificial intelligence for the diagnosis and prevention of hospital-acquired infections: A systematic review. *Diagnostics, 14*(5), 484. DOI	
9	Yachnaya, V. O., et al. Improving generalization in classification of novel bacterial strains: A multi-headed ResNet approach for microscopic image classification. *Computer Optics, 48*(5).	
10	Aytac, O., Senol, F. F., Kivrak, T., Toraman, Z. A., et al. (2025). MACNeXt-based bacteria species detection. *Microorganisms, 13*(12), 2689. DOI	
11	Wu, Y., & Gadsden, S. A. (2023). Machine learning algorithms in microbial classification: A comparative analysis. *Frontiers in Artificial Intelligence, 6*, 1200994. DOI	
12	Rattray, J. B., Lowhorn, R. J., Walden, R., Márquez-Zacarías, P., et al. (2023). Machine learning identification of *Pseudomonas aeruginosa* strains from colony image data. *PLOS Computational Biology, 19*(12), e1011699. DOI	
13	Samuel, L. P., Balada-Llasat, J.-M., Harrington, A., & Cavagnolo, R. (2016). Multicenter assessment of Gram stain error rates. *Journal of Clinical Microbiology, 54*(6), 1442–1447. DOI	
14	Mai, D.-T., & Ishibashi, K. (2021). Small-scale depthwise separable convolutional neural networks for bacteria classification. *Electronics, 10*(23), 3005. DOI	
15	Jones, G. L., & Dever, S. M. (1984). *The Gram stain: A new look at an old tool.* Centers for Disease Control.	

Gambar 10. *Validasi sumber NotebookLM oleh Claude.ai dan penggabungan seluruh sumber ke dalam satu tabel sumber final.*

Lampiran 2. Daftar Connector untuk Brainstorming dan Riset Referensi

Berikut adalah daftar connector yang tersedia dan digunakan sebagai sumber brainstorming serta riset referensi dalam menyelesaikan Studi Kasus A:

1. **BioRender**: alat untuk membuat ilustrasi dan diagram ilmiah (biologi, medis).
2. **bioRxiv**: akses preprint (naskah belum publikasi resmi) di bidang biologi.

3. **BioSkepsis**: komunitas/riset untuk diskusi kritis topik biosains.
4. **ChEMBL**: database senyawa kimia bioaktif dan data farmakologi.
5. **Clinical Trials**: pencarian data uji klinis (clinicaltrials.gov).
6. **Consensus**: mesin pencari akademik berbasis AI untuk merangkum temuan riset ilmiah.
7. **Elicit**: asisten riset AI untuk mencari dan menganalisis paper akademik.
8. **Encited**: komunitas untuk sitasi dan referensi riset.
9. **Firecrawl**: alat crawling/scraping website untuk mengambil konten web.
10. **Mermaid Chart**: pembuatan diagram dan flowchart berbasis teks (Mermaid syntax).
11. **Notion**: aplikasi catatan, dokumentasi, dan manajemen knowledge base.
12. **Open Targets**: platform riset target obat dan asosiasi penyakit-gen.
13. **PubMed**: database literatur biomedis dan ilmu kehidupan (life sciences).
14. **SciSpace**: platform membaca, mencari, dan memahami paper ilmiah dengan bantuan AI.
15. **Scite**: analisis sitasi untuk melihat konteks kutipan sebuah paper (didukung/dibantah).
16. **Synapse.org**: platform kolaborasi data biomedis dan genomik.
17. **Undermind**: mesin pencari riset ilmiah mendalam berbasis AI.
18. **Wiley Scholar Gateway**: akses jurnal dan publikasi ilmiah dari Wiley.

Lampiran 3. Tautan Proyek Implementasi

Desain konseptual pada laporan ini sedang dikembangkan lebih lanjut menjadi implementasi nyata oleh penulis, di luar cakupan penilaian tugas ini. Tautan berikut disertakan sebagai referensi tambahan bagi pembaca yang ingin melihat perkembangan proyek.

Judul proyek: BacteriaCV: Klasifikasi Bentuk Sel dan Status Gram Bakteri dari Citra Mikroskopis

Deskripsi singkat: Prototipe BacteriaCV telah diimplementasikan sebagai aplikasi web yang mengklasifikasikan bentuk sel (kokus atau basil) dan status Gram (positif

atau negatif) secara otomatis dari citra mikroskopis. Seluruh tahap pipeline pada Gambar 1 sudah berjalan: pra-pemrosesan citra, ekstraksi fitur dengan ResNet50 yang dibekukan, klasifikasi melalui dua head linear terpisah, dan segmentasi citra untuk visualisasi. Model dilatih pada 669 citra DIBaS dari 32 spesies, dengan pembagian 467 citra latih, 136 citra validasi, dan 66 citra uji. Pada data uji, skor F1 makro dan akurasi mencapai 1,0000 pada kedua head, dengan rata-rata confidence 0,9709 untuk bentuk sel dan 0,9921 untuk status Gram. Antarmuka menerima berkas berformat png, jpg, jpeg, tif, dan tiff dengan batas ukuran 20 MB. Setiap hasil menampilkan nilai confidence, lima panel visualisasi, dan catatan keterbatasan.

URL: https://bacteriacv-demo.up.railway.app